

Adapting performance metrics for ordinal classification to interval scale: length matters

Marcos Rivera Gavilán¹[0000–0002–2068–189X]

Department of Computer Sciences, Universidad de Córdoba, 14014 Córdoba, Spain
i92rigam@uco.es

Abstract. En problemas de clasificación ordinal, las clases tienen un orden natural (por ejemplo, intervalos de edad o niveles de satisfacción), pero con frecuencia se asume de manera implícita que las clases son equidistantes. Es decir, no se considera la posible diferencia real entre la longitud de cada intervalo. El objetivo principal de esta síntesis del artículo “Adapting performance metrics for ordinal classification to interval scale: length matters” [1], es analizar las adaptaciones de métricas comunes de clasificación ordinal (como MAE y TC) a escenarios en los que las categorías son intervalos con distintas longitudes.

A grandes rasgos, el artículo:

- Redefine la distancia entre clases de un simple $|i - j|$ (índices de clase) a la distancia real entre los intervalos que representan dichas clases.
- Sustituye el recuento de instancias por la “densidad” (número de instancias dividido por la longitud del intervalo), lo cual afecta la penalización de los errores.
- Normaliza las métricas resultantes a un rango $[0, 1]$, mejorando la interpretabilidad y facilitando la comparación entre distintos problemas de clasificación ordinal.
- Ofrece un enfoque para asignar una longitud finita a clases abiertas, de manera que la métrica resultante sea coherente y posibilite la comparación de clasificadores.

Los experimentos preliminares mostraron que estas métricas adaptadas pueden mejorar la selección de modelos en situaciones donde las clases no son equidistantes y, además, ofrecen una estimación más fidedigna del error real cometido por el clasificador.

Table of Contents

Adapting performance metrics for ordinal classification to interval scale: length matters	1
<i>Marcos Rivera Gavilán</i>	
1 Introducción	5
2 Antecedentes	6
2.1 Matriz de Confusión	6
2.2 MAE (Mean Absolute Error)	6
2.3 TC (Total Misclassification Cost)	6
2.4 Limitaciones Principales	7
3 Metodología	8
3.1 Normalización y Búsqueda de x	9
4 Resultados Experimentales	10
4.1 Ejemplo con Intervalo Abierto	10
4.2 Aplicaciones	11
4.3 Ejemplo	11
5 Discusión y Análisis	12
5.1 Fortalezas	12
5.2 Debilidades o Retos Abiertos	12
5.3 Posibles Extensiones Futuras	13
6 Conclusiones	14

1 Introducción

La clasificación ordinal se diferencia de la clasificación nominal en que las clases tienen una relación de orden. Un ejemplo típico es la discretización de la variable “edad” en intervalos: $[0, 10)$, $[10, 18)$, $[18, 65)$, $[65, \infty)$. La mayoría de las métricas ordinales tradicionales, como MAE (Mean Absolute Error) o TC (Total Misclassification Cost), suponen que la distancia entre la clase j y la clase $j + 1$ es la misma, ignorando la longitud real de los intervalos $[1, 3, 5]$.

No obstante, hay casos en los que un intervalo cubre un rango mucho mayor que otro, por lo que el error de predecir una instancia x en un intervalo lejano podría ser más grave o menos, según el tamaño real de los intervalos. Esto motiva la adaptación de dichas métricas a la denominada *escala de intervalos*.

Adicionalmente, la clasificación ordinal en entornos reales enfrenta el problema de la *clase abierta* en el extremo superior (o inferior), como por ejemplo $[65, \infty)$ al tratar con grupos de edad avanzada.

2 Antecedentes

La clasificación ordinal se sitúa entre la nominal y la regresión pura: las clases son categorías ordenadas. Para cuantificar errores, surgen métricas como MAE o TC, cuyos detalles se exponen a continuación.

2.1 Matriz de Confusión

Dado un problema con r clases ordenadas $(1, 2, \dots, r)$, al usar un clasificador obtenemos una matriz de confusión $A = (a_{ij})$, donde a_{ij} es el número de instancias de la clase real j clasificadas como i . Si se denota $N = \sum_{i,j} a_{ij}$, se pueden definir varias métricas.

2.2 MAE (Mean Absolute Error)

Es una métrica ampliamente utilizada:

$$MAE(A) = \frac{1}{N} \sum_{i,j} a_{ij} |i - j|.$$

Refleja la magnitud del error ordinal, penalizando más si la predicción se aleja en más niveles de clase. Sin embargo, **no** considera la longitud real entre los intervalos: solo usa la diferencia de índices [2].

2.3 TC (Total Misclassification Cost)

Propuesta en [4], incorpora la dimensión del *costo* de equivocarse entre clases más (o menos) pobladas:

$$TC(A) = \sum_{i,j} a_{ij} \omega_{ij} |i - j| \quad \text{con} \quad \omega_{ij} = \frac{N - n_j}{n_i}.$$

Es útil en contextos con desequilibrio de clases. Aun así, sigue asumiendo distancia ordinal uniforme, *obviando* la posible longitud distinta de cada intervalo.

2.4 Limitaciones Principales

Ambas métricas, MAE y TC, parten de $|i - j|$ para medir la distancia entre clases. Esto resulta demasiado rígido cuando las clases representan intervalos de distinta amplitud. Un error de saltar de $[18, 65)$ a $[10, 18)$ es la misma distancia ordinal que saltar de $[10, 18)$ a $[0, 10)$, aunque las longitudes de estos tramos sean muy diferentes. Asimismo, no contemplan la gestión natural de intervalos abiertos, p.ej. $[65, \infty)$.

3 Metodología

Para incorporar la longitud real de cada clase-intervalo en las métricas, la propuesta se basa en:

1. **Definir la distancia entre intervalos.** Se sustituye $|i - j|$ por $d(I_i, I_j)$, donde $I_i = [a_i, b_i)$ y se sugiere la *distancia de Hausdorff*:

$$d(I_i, I_j) = \max\{|a_j - a_i|, |b_j - b_i|\}.$$

2. **Cambiar el conteo por densidad.** En vez de usar n_j (número de instancias en clase j), se emplea $\delta_j = \frac{n_j}{\ell_j}$, con $\ell_j = b_j - a_j$ (longitud del intervalo).
3. **Crear métricas intervalares (MAE_{int} , TC_{int}).** Se redefinen:

$$MAE_{int}(A) = \frac{1}{N} \sum_{i,j} a_{ij} d(I_i, I_j),$$

$$TC_{int}(A) = \sum_{i,j} a_{ij} \gamma_{ij}^{int} d(I_i, I_j), \quad \text{donde} \quad \gamma_{ij}^{int} = \frac{\sum_{k \neq j} \ell_k}{\ell_i}.$$

4. **Normalizar a $[0, 1]$.** Para cada métrica M_{int} se calcula su máximo teórico $M_{int}^{\max}$ (peor clasificación posible) y luego se define $\widehat{M}_{int}(A) = \frac{M_{int}(A)}{M_{int}^{\max}}$ para A en la matriz de confusión. Así se sitúa en $[0, 1]$ y se favorece la interpretabilidad.
5. **Asignar longitud finita en la clase abierta.** Si la última clase $[a_r, \infty)$ no tiene límite superior, se asigna un valor $x > 0$, de modo que $b_r = a_r + x$. Se propone optimizar x minimizando el máximo teórico de la métrica, para dar la máxima sensibilidad.

3.1 Normalización y Búsqueda de x

El valor óptimo de x no es trivial cuando la clase es abierta. Para un conjunto de datos fijo (donde n_j y ℓ_j para $j < r$ son conocidos), se define

$$x_{\min} = \arg \min_{x > 0} M_{int}^{\max}(x).$$

Asignando esa longitud finita $x_{\min}$ al intervalo superior, se logra una versión de la métrica con mayor capacidad de discriminar entre distintos clasificadores. Ejemplos analíticos y numéricos demuestran que, para muchos casos, $x_{\min}$ se mantiene por debajo de la suma de las longitudes de los otros intervalos [1].

4 Resultados Experimentales

4.1 Ejemplo con Intervalo Abierto

Supongamos 3 clases: $I_1 = [0, 10)$, $I_2 = [10, 20)$ y $I_3 = [20, \infty)$. El último intervalo es abierto. Un clasificador A y otro B dan matrices de confusión distintas. Al variar la longitud asignada a I_3 , se modifica la penalización de los errores que implican la clase I_3 . Se observa que hay un valor $x_{\min}$ que maximiza la diferencia entre las puntuaciones de A y B, reflejando mejor cuál es superior [1].




Fig. 1. Esquema metodológico para adaptar métricas ordinales a la escala de intervalos, introducido en [1]. Se sustituyen distancias y recuentos para reflejar la longitud real.

4.2 Aplicaciones

En [1] se realizaron experimentos con conjuntos de datos donde la variable a predecir se discretiza en intervalos (por ejemplo, edad ≥ 60), mostrando:

- Las métricas intervalares $\widehat{MAE}_{int}$, $\widehat{TC}_{int}$ guían mejor la selección de hiperparámetros en clasificadores de tipo *random forest* o *kNN*.
- La elección de x para el intervalo abierto influye significativamente en la sensibilidad de la métrica.
- Para muchos conjuntos de datos, el $x_{\min}$ obtenido no supera la suma de los intervalos previos, facilitando la búsqueda en un rango acotado.

4.3 Ejemplo

Para ilustrar, la Tabla 1 muestra resultados sintéticos de dos clasificadores (A y B) en un caso con $r = 3$ intervalos, comparando Accuracy, MAE, y la métrica $\widehat{MAE}_{int}$ con distintas longitudes x asignadas a la clase abierta final:

Table 1. Comparación de métricas (ejemplo sintético)

Classificador	Accuracy	MAE	$\widehat{MAE}_{int}$ con $x =$		
			10	20	50
(lr)4-6					
A	0.76	0.37	0.22	0.18	0.15
B	0.75	0.36	0.28	0.25	0.22

Como se aprecia, el clasificador A y B tienen *Accuracy* similar, pero difieren más apreciablemente al usar $\widehat{MAE}_{int}$, en especial con $x = 50$, reflejando mejor la gravedad de confundirse en un intervalo amplio.

5 Discusión y Análisis

En esta sección se discuten fortalezas, limitaciones y posibles mejoras de la propuesta de adaptación de métricas ordinales a la escala de intervalos.

5.1 Fortalezas

- **Mayor realismo en la penalización de errores:** Al emplear la distancia entre intervalos y la densidad, se representa mejor la magnitud real del error.
- **Flexibilidad de implementación:** Cualquier métrica basada en la matriz de confusión, como MAE, TC u otras, puede adaptarse al seguir esta misma lógica.
- **Solución al intervalo abierto:** La propuesta de elegir un x que minimice el máximo teórico es elegante y práctica, permitiendo un uso consistente de la métrica.
- **Normalización en $[0, 1]$:** Facilita comparar diferentes conjuntos de datos y distintos problemas, unificando criterios de evaluación.

5.2 Debilidades o Retos Abiertos

- **Elección de la distancia:** Se usa la distancia de Hausdorff, pero podrían existir otras definiciones de distancia entre intervalos (e.g. distancia promedio) que resulten apropiadas en ciertos contextos.
- **Costo computacional para optimizar x :** En problemas con muchos intervalos abiertos o grandes bases de datos, la búsqueda de $x_{\min}$ podría requerir métodos numéricos más complejos.
- **Adopción en entornos reales:** Pese a sus ventajas, muchos dominios (e.g. clínico, financiero) están acostumbrados a métricas tradicionales. Se requerirá divulgación y validación adicional para su adopción.
- **Selección del factor de densidad:** Al normalizar por la longitud del intervalo, se asume que la densidad es la medida adecuada de “peso” de la clase. En casos con sesgos importantes en la distribución, podría estudiarse otra ponderación.

5.3 Posibles Extensiones Futuras

- **Ajuste dinámico de la longitud abierta:** Explorar esquemas bayesianos o de estimación de densidad donde la longitud de la clase abierta se actualice con datos adicionales.
- **Distancias alternativas:** Analizar empíricamente si otras distancias (p.ej. Minkowski) ofrecen diferencias significativas en problemas reales.
- **Formalizar otras métricas:** Llevar la misma lógica a métricas como F_1 ordinal o kappa ponderado, con un análogo adaptado a intervalos.
- **Aplicaciones a escalas ordinales no numéricas:** Aunque aquí se habla de intervalos numéricos, se podrían diseñar mapeos similares para variables ordinales con significado semántico (bajo/medio/alto) de distinta “amplitud conceptual”.

6 Conclusiones

La incorporación de la longitud real de los intervalos en problemas de clasificación ordinal atiende una necesidad práctica: en muchos casos las clases representan rangos numéricos no equidistantes y la penalización de errores debería reflejar *cuán grande* es el salto entre clases.

Las métricas propuestas en [1] abordan este aspecto mediante:

1. El reemplazo de la diferencia de índices $|i - j|$ por una distancia entre intervalos (Hausdorff u otra).
2. La sustitución del recuento simple por densidades de clase, incorporando la longitud real de cada intervalo.
3. Un proceso de normalización que sitúa la métrica en $[0, 1]$, facilitando su interpretación.
4. Un método de asignación de una longitud finita a la clase abierta que maximiza la sensibilidad de la métrica.

Las evidencias preliminares sugieren que estas métricas *intervalares* pueden guiar mejor la selección de hiperparámetros y ofrecer una visión más ajustada del costo real de los errores. No obstante, quedan abiertas líneas de investigación acerca de qué tipo de distancia usar, cómo optimizar la longitud abierta en situaciones más complejas y cómo favorecer su adopción en ámbitos donde prevalecen las métricas tradicionales (accuracy, F1, AUC, etc.).

En definitiva, la adaptación de métricas ordinales a la escala de intervalos supone un avance significativo en la evaluación de clasificadores para escenarios con clases de distinta amplitud, permitiendo decisiones más coherentes con la realidad cuantitativa subyacente.

References

1. Binotto, G., Delgado, R.: *Adapting performance metrics for ordinal classification to interval scale: length matters*. Machine Learning (2025) 114:41–49 (2025)
2. Baccianella, S., Esuli, A., & Sebastiani, F.: Evaluation measures for ordinal regression. *Proceedings of the 2009 IEEE International Conference on Intelligent Systems Design and Applications*, 283–287 (2009)
3. Cruz-Ramírez, M., Hervás-Martínez, C., Sánchez-Monedero, J., & Gutiérrez, P. A.: A preliminary study of ordinal metrics to guide a multi-objective evolutionary algorithm. *International Conference on Intelligent Systems Design and Applications*, 1176–1181 (2011)
4. George, N. I., Lu, T.-P., & Chang, C.-W.: Cost-sensitive performance metric for comparing multiple ordinal classifiers. *Artificial Intelligence Research*, 5(1), 135–143 (2016)
5. Liu, X. et al.: Unimodal regularized neuron stick-breaking for ordinal classification. *Neurocomputing*, 388, 34–44 (2020)