

Adapting performance metrics for ordinal classification to interval scale: length matters

Marcos Rivera Gavilán¹[0000–0002–2068–189X]

Department of Computer Sciences, Universidad de Córdoba, 14014 Córdoba, Spain
i92rigam@uco.es

Abstract. En problemas de clasificación ordinal, las clases tienen un orden natural (por ejemplo, intervalos de edad o niveles de satisfacción), pero con frecuencia se asume de manera implícita que las clases son equidistantes. Es decir, no se considera la posible diferencia real entre la longitud de cada intervalo. El objetivo principal de esta síntesis del artículo “Adapting performance metrics for ordinal classification to interval scale: length matters” [1], es analizar las adaptaciones de métricas comunes de clasificación ordinal (como MAE y TC) a escenarios en los que las categorías son intervalos con distintas longitudes.

A grandes rasgos, el artículo:

- Redefine la distancia entre clases de un simple $|i - j|$ (índices de clase) a la distancia real entre los intervalos que representan dichas clases.
- Sustituye el recuento de instancias por la “densidad” (número de instancias dividido por la longitud del intervalo), lo cual afecta la penalización de los errores.
- Normaliza las métricas resultantes a un rango $[0, 1]$, mejorando la interpretabilidad y facilitando la comparación entre distintos problemas de clasificación ordinal.
- Ofrece un enfoque para asignar una longitud finita a clases abiertas, de manera que la métrica resultante sea coherente y posibilite la comparación de clasificadores.

Los experimentos preliminares mostraron que estas métricas adaptadas pueden mejorar la selección de modelos en situaciones donde las clases no son equidistantes y, además, ofrecen una estimación más fidedigna del error real cometido por el clasificador.

Table of Contents

Adapting performance metrics for ordinal classification to interval scale: length matters	1
<i>Marcos Rivera Gavilán</i>	
1 Introducción	5
2 Antecedentes	6
2.1 Matriz de Confusión	6
2.2 MAE (Mean Absolute Error)	6
2.3 TC (Total Misclassification Cost)	7
2.4 Limitaciones Principales	7
3 Metodología	8
3.1 Normalización y Búsqueda de $\mathbf{x}$	9
4 Resultados	11
4.1 Problema con Intervalo Abierto	11
4.2 Aplicaciones	11
4.3 Ejemplo	12
5 Discusión y Análisis	13
5.1 Fortalezas	13
5.2 Retos	13
5.3 Extensiones Futuras	14
6 Conclusiones	15

1 Introducción

La clasificación ordinal se sitúa en un punto intermedio entre la clasificación nominal —donde no existe una relación de orden entre las clases— y la regresión, la cual trabaja sobre valores continuos. En la clasificación ordinal, las categorías mantienen un orden inherente (por ejemplo, bajo < medio < alto), pero no necesariamente se cuenta con una escala métrica que permita cuantificar la distancia entre una clase y la siguiente. Un ejemplo muy frecuente es la segmentación de la edad en rangos sucesivos, como $[0, 10)$, $[10, 18)$, $[18, 65)$, $[65, \infty)$. Estas franjas de edad, si bien están ordenadas (al aumentar la edad se salta al intervalo siguiente), pueden variar notablemente en su longitud real, lo que implica que un error al clasificar a una persona de 70 años en el rango $[18, 65)$ es muy distinto de clasificar a una persona de 20 años en $[10, 18)$. Sin embargo, la mayoría de las métricas ordinales (p.ej. MAE o TC) tratan ambos errores con la misma penalización si únicamente consideran la distancia ordinal como $|i - j|$.

En entornos reales, se recurre con frecuencia a esta clase de discretizaciones por motivos prácticos: las políticas de salud o de precios de seguros, por ejemplo, se aplican habitualmente por intervalos de edad, sin llegar a manejar valores puntuales. Sin embargo, esto genera el reto de que algunos intervalos pueden cubrir rangos muy amplios —como ocurre con la clase *abierta* $[65, \infty)$ — o bien tramos más estrechos donde, teóricamente, los errores deberían penalizarse menos. Surge así la motivación para adaptar las métricas ordinales a la escala de intervalos: donde en vez de asumir que las clases son simples posiciones $1, 2, \dots, r$ en un eje, se consideran las longitudes reales que cada categoría abarca y, a la vez, se maneja apropiadamente la presencia de intervalos abiertos. Este refinamiento permite alinear mejor la penalización de los errores con la magnitud real de la confusión, ofreciendo una evaluación más realista de los clasificadores en situaciones donde “la longitud del salto” entre clases sí importa.

2 Antecedentes

Para evaluar el rendimiento de los modelos ordinales, se han propuesto diversas métricas especializadas. A continuación, revisamos dos de las más utilizadas: *MAE* (Mean Absolute Error) y *TC* (Total Misclassification Cost).

2.1 Matriz de Confusión

Sea un problema con r clases ordenadas, etiquetadas como $1, 2, \dots, r$. Al aplicar un clasificador a un conjunto de validación, se construye la matriz de confusión $A = (a_{ij})$, donde a_{ij} representa el número de instancias que pertenecen realmente a la clase j y que han sido clasificadas como i . Denotamos

$$N = \sum_{i=1}^r \sum_{j=1}^r a_{ij}$$

como el número total de instancias en dicha validación. Sobre esta matriz de confusión se definen las métricas presentadas a continuación.

2.2 MAE (Mean Absolute Error)

El *Mean Absolute Error* (MAE) es una métrica ampliamente empleada en contextos de clasificación ordinal. Su definición se basa en la distancia absoluta entre la clase real y la clase predicha, promediada sobre todas las instancias:

$$MAE(A) = \frac{1}{N} \sum_{i=1}^r \sum_{j=1}^r a_{ij} |i - j|.$$

El MAE penaliza más a aquellos clasificadores que tienden a equivocarse con clases muy lejanas de la verdadera; sin embargo, es importante notar que **no** contempla la longitud real de los intervalos asociados a cada clase, sino únicamente la diferencia de índices [2]. Esto puede resultar insuficiente cuando las clases representan segmentos de diferente amplitud, como ocurre a menudo con rangos de edad o niveles cuantitativos de otra índole.

2.3 TC (Total Misclassification Cost)

La métrica *Total Misclassification Cost* (TC), introducida en [4], incorpora una noción de costo por equivocarse en clasificar la instancia de una clase en otra. Se define como:

$$TC(A) = \sum_{i=1}^r \sum_{j=1}^r a_{ij} \omega_{ij} |i - j|, \quad \text{con} \quad \omega_{ij} = \frac{N - n_j}{n_i},$$

donde $n_j = \sum_{i=1}^r a_{ij}$ es el número total de instancias de la clase j . Esta formulación intenta capturar la idea de que equivocarse con una clase muy pequeña (o al clasificar instancias de una clase numerosa hacia otra pequeña) puede ser más costoso, reflejando así la influencia del desequilibrio entre clases. No obstante, TC asume también una distancia ordinal uniforme $|i - j|$, sin considerar la longitud real de los intervalos subyacentes y, por ende, sin discriminar entre clases que pueden abarcar regiones muy distintas en la variable continua que se está segmentando.

2.4 Limitaciones Principales

Tanto el MAE como el TC se basan en la diferencia de índices $|i - j|$ para medir la distancia entre clases. Esto se vuelve excesivamente restrictivo cuando las clases representan intervalos con amplitudes diferentes. Así, un salto desde $[18, 65)$ a $[10, 18)$ recibe la misma penalización ordinal que saltar de $[10, 18)$ a $[0, 10)$, pese a que esos intervalos difieren sustancialmente en longitud. Además, ninguna de estas métricas aborda por defecto la gestión de intervalos abiertos (por ejemplo, $[65, \infty)$), caso muy común en la práctica cuando se discretizan variables como la edad.

3 Metodología

Para abordar las limitaciones expuestas en la sección anterior, se propone un esquema que incorpore la longitud real de cada intervalo en el cálculo de las métricas. La idea central consiste en reemplazar la distancia ordinal $|i - j|$ por la distancia entre los intervalos que representan las clases, y sustituir el simple recuento de instancias n_j por un valor de *densidad*, que tenga en cuenta la longitud de cada intervalo. A continuación, se describen los pasos principales:

1. **Definir la distancia entre intervalos.** En vez de tomar la diferencia de índices $i - j$, se propone usar una medida de distancia para los intervalos reales. Si se denota la i -ésima clase como $I_i = [a_i, b_i)$, puede emplearse la *distancia de Hausdorff*:

$$d(I_i, I_j) = \max\{a_j - a_i, b_j - b_i\}.$$

Esta métrica mide la distancia máxima entre los extremos de los intervalos, adecuándose de forma natural a rangos de distinto tamaño.

2. **Cambiar el conteo por densidad.** En lugar de utilizar n_j como el número de instancias de la clase j , se define la *densidad*:

$$\delta_j = \frac{n_j}{\ell_j}, \quad \text{donde} \quad \ell_j = b_j - a_j$$

es la longitud real del intervalo I_j . Así, si un intervalo cubre un rango muy amplio pero no contiene muchas instancias, su densidad será pequeña, y viceversa.

3. **Crear métricas intervalares** (MAE_{int}, TC_{int}). A continuación, las métricas ordinales se adaptan sustituyendo la distancia $i - j$ por $d(I_i, I_j)$ y el recuento n_j por ℓ_j (o, de forma equivalente, introduciendo las densidades). De esta forma:

$$MAE_{int}(A) = \frac{1}{N} \sum_{i,j} a_{ij} d(I_i, I_j),$$

$$TC_{int}(A) = \sum_{i,j} a_{ij} \gamma_{ij}^{int} d(I_i, I_j), \quad \text{donde} \quad \gamma_{ij}^{int} = \frac{\sum_{k \neq j} \ell_k}{\ell_i}.$$

En estas expresiones, N mantiene el significado de número total de instancias, y a_{ij} son los valores de la matriz de confusión.

4. **Normalizar a $[0, 1]$.** Para facilitar la interpretación y comparación entre diversos contextos, se define una versión normalizada. Primero se calcula el valor máximo teórico $M_{int}^{\max}$ (aquél que obtiene la peor clasificación posible en la matriz de confusión). Entonces se normaliza:

$$\widehat{M}_{int}(A) = \frac{M_{int}(A)}{M_{int}^{\max}}.$$

Así, la métrica se acota entre 0 y 1, lo que permite un análisis más claro del error.

5. **Asignar longitud finita en la clase abierta.** Por último, para el caso frecuente en que la última clase sea abierta, es decir, $[a_r, \infty)$, se propone asignarle una longitud finita $x > 0$ tal que su extremo superior sea $b_r = a_r + x$. Con el fin de maximizar la sensibilidad de la métrica, se sugiere escoger x minimizando el máximo teórico de la misma, $M_{int}^{\max}(x)$. De este modo se obtiene un valor óptimo $x_{\min}$ que mejora la discriminación entre clasificadores.

3.1 Normalización y Búsqueda de x

El paso de asignar una longitud finita a la clase abierta no siempre es trivial. Dado un conjunto de datos donde las primeras $r - 1$ clases tengan longitudes $\ell_1, \ell_2, \dots, \ell_{r-1}$ fijas y respectivos recuentos de instancias $n_1, \dots, n_{r-1}$, se desea encontrar el valor

$$x_{\min} = \arg \min_{x > 0} M_{int}^{\max}(x),$$

es decir, el x que minimiza la cota superior de la métrica intervalar. Asignar de esta forma la longitud al último intervalo potencia la sensibilidad de la métrica y evita asignaciones arbitrarias. En varios ejemplos analíticos y numéricos presentados en [1], se observa que $x_{\min}$ suele ser menor a la suma de las longitudes de los otros intervalos, lo que permite acotar razonablemente la búsqueda.




Fig. 1. Esquema metodológico para adaptar métricas ordinales a la escala de intervalos, introducido en [1]. Se sustituyen distancias y recuentos para reflejar la longitud real.

En la figura se muestra de forma esquemática el proceso de conversión de una métrica ordinal (basada en $i - j$) a una métrica *intervalar*, donde tanto la longitud de los intervalos como la densidad de cada clase juegan un papel fundamental.

4 Resultados

4.1 Problema con Intervalo Abierto

Consideremos un problema de clasificación con tres clases: $I_1 = [0, 10)$, $I_2 = [10, 20)$ y $I_3 = [20, \infty)$. Aquí, el último intervalo I_3 es *abierto*, puesto que no se establece un límite superior fijo. Supongamos que contamos con dos clasificadores distintos, A y B, cuyas matrices de confusión difieren en la forma de clasificar instancias que caen en la región correspondiente a I_3 .

Al variar la longitud que asignamos a I_3 —es decir, al reemplazar el intervalo $[20, \infty)$ por $[20, 20+x)$ —, se modifican de manera significativa las penalizaciones de los errores en esta clase. En el artículo se observa que existe un valor $x_{\min}$ que *maximiza la diferencia* entre las puntuaciones de A y B, reflejando de forma más nítida cuál de los dos clasificadores rinde mejor. De este modo, la elección de x no es arbitraria, sino que se basa en el criterio de minimizar el máximo teórico de la métrica adaptada.

4.2 Aplicaciones

En el trabajo original [1], se realizaron experimentos extensivos con varios conjuntos de datos donde la variable a predecir se divide en intervalos (por ejemplo, una edad ≥ 60). Los hallazgos principales fueron los siguientes:

- Las versiones intervalares $\widehat{MAE}_{int}$ y $\widehat{TC}_{int}$ mostraron ser más fiables para guiar la selección de hiperparámetros de clasificadores *random forest* y *kNN*, en comparación con sus contrapartidas ordinales.
- La longitud x que se asigna a un intervalo abierto influye fuertemente en la sensibilidad de la métrica, dando lugar a decisiones de clasificación diferentes.
- En numerosos casos de estudio, el $x_{\min}$ óptimo no supera la suma de las longitudes de los intervalos anteriores, lo que posibilita restringir la búsqueda de manera eficiente.


4.3 Ejemplo

Para ejemplificar estas diferencias, la Tabla 1 compara dos clasificadores (A y B) en un problema con $r = 3$ intervalos, donde la clase final es abierta. Se presentan resultados de *Accuracy*, *MAE* y la métrica adaptada $\widehat{MAE}_{int}$ para distintas longitudes x asignadas a la clase abierta:

Table 1. Comparación de métricas (ejemplo sintético).

Clasificador	Accuracy	MAE	$\widehat{MAE}_{int}$ con $x =$		
			(lr)4-6	10	20
A	0.76	0.37	0.22	0.18	0.15
B	0.75	0.36	0.28	0.25	0.22

Aunque los dos clasificadores A y B obtienen valores de *Accuracy* similares, la métrica $\widehat{MAE}_{int}$ revela diferencias más notables, especialmente cuando el intervalo abierto tiene una longitud de 50. Este caso sugiere que clasificar erróneamente a una persona cerca de los 65 años no es lo mismo que clasificar erróneamente a alguien con 75 o 80 años, resaltando así la importancia de la longitud real del intervalo final en la evaluación.



(a) Facial age dataset. Random forest

Fig. 2. Boxplot de la métrica SMAE.int. Cada caja corresponde a una asignación distinta de la longitud del intervalo derecho.

En la Figura 2, por ejemplo, se presenta la distribución (en forma de box-plot) de la métrica SMAE.int en un conjunto de datos reales de *edad facial*, variando la longitud asignada al último intervalo. Se aprecia cómo, al incrementar dicha longitud, la métrica se ve modificada, ofreciendo diferentes valoraciones del rendimiento de un mismo clasificador.

5 Discusión y Análisis

5.1 Fortalezas

- **Mayor precisión en la penalización de errores.** Al emplear la distancia entre intervalos y la densidad (en lugar de índices fijos y recuentos absolutos), se logra una mejor aproximación de la magnitud real del error; un salto entre intervalos muy dispares se penaliza más que uno entre intervalos contiguos o de longitud reducida.
- **Flexibilidad de implementación.** Este enfoque puede aplicarse a distintas métricas ordinales que dependan de la matriz de confusión (por ejemplo, MAE, TC o sus variantes), ya que la lógica de sustitución de distancias y recuentos es general.
- **Solución al intervalo abierto.** Al proponer un criterio para determinar x que minimice el máximo teórico de la métrica, se introduce una manera coherente y práctica de acotar un intervalo nominalmente infinito, haciendo viable la evaluación.
- **Normalización en $[0, 1]$.** El hecho de escalar la métrica al rango $[0, 1]$ permite realizar comparaciones consistentes entre distintos problemas y conjuntos de datos, lo cual es de gran ayuda para análisis de múltiples escenarios.

5.2 Retos

- **Elección de la distancia entre intervalos.** En este trabajo se propone la distancia de Hausdorff como base, pero podrían existir otras definiciones (distancia promedio, Minkowski, etc.) que, en determinados contextos, resulten más adecuadas. La selección óptima dependerá del problema y la naturaleza de la variable continua subyacente.
- **Costo computacional para optimizar x .** En situaciones con múltiples intervalos abiertos (o bases de datos muy grandes), hallar $x_{\min}$ puede requerir procesos de optimización numérica más sofisticados, o bien aproximaciones con métodos heurísticos.
- **Adopción en entornos reales.** Aunque las ventajas teóricas son claras, en ámbitos como el clínico o financiero se utilizan métricas muy establecidas (por ejemplo, Accuracy, Sensitivity, F1, etc.). Sería necesaria una labor de concienciación y validación adicional para que estas métricas adaptadas tuvieran una adopción significativa.
- **Selección del factor de densidad.** La propuesta asume que la densidad, definida como n_j/ℓ_j , es el mejor factor de “peso” en cada intervalo. En contextos con distribuciones muy sesgadas, cabría explorar otras ponderaciones o normalizaciones.

5.3 Extensiones Futuras

- **Ajuste dinámico de la longitud abierta.** Una vía interesante es incorporar modelos de estimación de densidad o enfoques bayesianos para recalcular x conforme se disponga de nuevos datos, permitiendo un refinamiento de la métrica a lo largo del tiempo.
- **Distancias alternativas.** Sería valioso explorar experimentalmente si otras distancias ofrecen ventajas en distintos escenarios de aplicación, ajustando mejor la penalización de errores.
- **Formalizar otras métricas.** Además de MAE y TC, existen otros indicadores en el ámbito ordinal (como F_1 ordinal, versiones ponderadas de kappa, etc.) que podrían ser adaptados con la misma lógica de intervalos, densidad y normalización.
- **Aplicaciones a escalas ordinales no numéricas.** Aunque aquí se tratan intervalos numéricos, también es posible imaginar categorías con distinta “amplitud conceptual” (p. ej. bajo < medio < alto), donde un modelo de mapeo a intervalos virtuales podría implementar esta adaptación.

6 Conclusiones

La incorporación de la longitud real de los intervalos en problemas de clasificación ordinal responde a una demanda práctica: frecuentemente, las clases se definen como rangos numéricos con extensiones desiguales, y resulta pertinente que la penalización de errores refleje la magnitud de dicha discrepancia. A lo largo de este trabajo, se ha visto cómo un mismo salto ordinal puede tener consecuencias distintas si los intervalos representan tramos muy diferentes de la variable continua.

Las métricas propuestas en [1] abordan esta problemática a través de:

1. El reemplazo de la distancia ordinal $|i - j|$ por una distancia real entre intervalos (p. ej. distancia de Hausdorff).
2. La introducción de la densidad de clase, al dividir el recuento de instancias n_j por la longitud física del intervalo ℓ_j .
3. Un proceso de normalización que encuadra los valores métricos en $[0, 1]$, facilitando la comparación e interpretación.
4. Un método para asignar una longitud finita a la clase abierta, optimizando la sensibilidad de la métrica a las diferencias de rendimiento entre clasificadores.

Los resultados preliminares sugieren que estas métricas *intervalares* pueden guiar de manera más certera la selección de hiperparámetros y proporcionar una estimación más verídica del costo real de los errores. Sin embargo, se abren diversas direcciones futuras: explorar distancias, profundizar en la asignación óptima de la longitud abierta para varios intervalos simultáneos y promover su adopción en contextos donde imperan medidas como *accuracy*, *F1* o *AUC*.

En síntesis, la adaptación de métricas ordinales a la escala de intervalos representa un paso significativo hacia una evaluación más fiel de clasificadores que trabajan con clases de amplitud distinta, permitiendo decisiones más coherentes con la realidad cuantitativa que subyace a la variable de interés.

References

1. G. Binotto and R. Delgado, "Adapting performance metrics for ordinal classification to interval scale: length matters," **Machine Learning**, vol. 114, p. 41, 2025. <https://doi.org/10.1007/s10994-024-06654-4>
2. S. Baccianella, A. Esuli, and F. Sebastiani, "Evaluation measures for ordinal regression," in **Proceedings of the 9th International Conference on Intelligent Systems Design and Applications (ISDA)**, 2009, pp. 283–287. <https://doi.org/10.1109/ISDA.2009.230>
3. M. Cruz-Ramírez, C. Hervás-Martínez, J. Sánchez-Monedero, and P. A. Gutiérrez, "A preliminary study of ordinal metrics to guide a multi-objective evolutionary algorithm," in **2011 11th International Conference on Intelligent Systems Design and Applications (ISDA)**, Cordoba, Spain, 2011, pp. 1176–1181. <https://doi.org/10.1109/ISDA.2011.6121818>
4. N. I. George, T.-P. Lu, and C.-W. Chang, "Cost-sensitive performance metric for comparing multiple ordinal classifiers," **Artificial Intelligence Research**, vol. 5, no. 1, pp. 135–143, 2016. <https://doi.org/10.5430/air.v5n1p135>
5. X. Liu, F. Fan, L. Kong, Z. Diao, W. Xie, J. Lu, and J. You, "Unimodal regularized neuron stick-breaking for ordinal classification," **Neurocomputing**, vol. 388, pp. 34–44, 2020. <https://doi.org/10.1016/j.neucom.2020.01.025>