

Máster Universitario en Inteligencia Computacional e Internet de las Cosas

Aprendizaje Profundo

*Adapting performance metrics for ordinal
classification to interval scale: length matters*

Autor:

Marcos Rivera Gavilán

Profesores:

Pedro Antonio Gutierrez Peña

Javier Sánchez Monedero

Índice

1. Introducción
2. Métricas
3. Propuesta
4. Resultados



Introducción


¿Qué es la clasificación ordinal?
¿Diferencias con otros tipos de clasificación?

¿Qué es la clasificación ordinal?

Es un tipo de clasificación donde las clases tienen un orden natural, pero no hay una distancia fija entre ellas.

Se usa cuando el error no debe ser penalizado igual si la predicción está cerca o lejos de la clase real.





¿Diferencias con otros tipos de clasificación?

Clasificación nominal:
Las clases no tienen orden
Cualquier error cuenta igual.

Clasificación ordinal:
Las clases sí tienen un orden
No es lo mismo equivocarse por poco que por mucho.


Métricas

¿Cómo medimos el rendimiento?
Limitaciones del MAE y TC

¿Cómo medimos el rendimiento?

Existen distintas métricas de evaluación según el tipo de tarea de aprendizaje automático. En clasificación, solemos usar Accuracy, AUC o Precision-Recall.

Para regresión, se utilizan errores como MAE o R^2 . En modelos no supervisados, se mide la calidad del agrupamiento. Esta imagen resume cómo varían las métricas según el tipo de problema.



$$\text{MAE}(C) = \frac{1}{N} \sum_{i,j=1}^r C_{ij} |i - j|$$

$$\text{TC}_j(C) = \sum_{i=1}^r C_{ij} \gamma_{ij} |i - j|$$

Limitaciones del MAE y TC

Ambas métricas sólo consideran la distancia entre clases como la diferencia entre índices $|i-j|$.

Ambas métricas ignoran la longitud real de los intervalos

Esto hace que si una clase representa un rango muy amplio, donde un error puede ser mucho más grave, estas métricas no lo reflejan.

Propuesta



¿Cómo incorporar los tamaños de los intervalos?
¿Qué hacer cuando una clase no tiene límite?

¿Cómo incorporar los tamaños de los intervalos?

En vez de usar solo las posiciones de clase, se usa la distancia real entre intervalos. También se considera la densidad de datos en cada intervalo.

Redefiniendo así cualquier métrica ordinal para que tenga en cuenta:

- Qué tan lejos están realmente las clases.
- Cuántos datos hay en cada una.
- Y se normaliza para tener un valor entre 0 y 1.



ESCALA DE MAR DOUGLAS			
Escala Beaufort	Descripción Douglas	Altura de olas	Grado
0	Llana	0 mts.	0
1	Rizada	0 – 0,25 mts.	1
2			
3	Marejadilla	0,25 – 0,5 mts.	2
4	Marejada	0,5 – 1,25 mts.	3
5	Fuerte marejada	1,25 – 2,5 mts.	4
6	Mar gruesa	2,5 – 4,0 mts.	5
7	Muy gruesa	4,0 – 6,0 mts.	6
8	Arbolada	6,0 – 9,0 mts.	7
9			
10	Montañosa	9,0 – 14 mts.	8
11			
12	Enorme	+ 14 mts.	9

¿Qué hacer cuando una clase no tiene límite?

En muchos casos, el último intervalo es abierto, lo que representa un problema para las métricas, ya que estas dependen del tamaño del intervalo.

En este trabajo, se estima una longitud óptima para dicho intervalo, ajustando según el comportamiento del modelo cómo esta longitud afecta el rendimiento medido por las métricas.


Resultados

¿Mejoran usando métricas adaptadas?
Conclusiones y aportes

¿Mejoran usando métricas adaptadas?

La gráfica muestra cómo varía el rendimiento (menor es mejor) al asignar diferentes longitudes al último intervalo abierto.

Utilizando una métrica adaptada a la escala de intervalo (SMAE.int), se observa que el modelo logra un mejor desempeño cuando se ajusta correctamente esta longitud.



(a) Facial age dataset. Random forest

$$\widehat{\text{MAE}}(A) = \frac{\text{MAE}(A)}{\text{MAE}_{\max}}$$

$$\widehat{\text{TC}}(A) = \frac{\text{TC}(A)}{\text{TC}_{\max}}$$

Conclusiones y aportes

Introduciendo versiones normalizadas de las métricas MAE y TC, cada valor se ajusta con respecto al máximo que podrían alcanzar en la matriz de confusión.

Esto permite comparar modelos entre sí, independientemente del número de clases o su distribución, y facilita el análisis cuando se incorporan intervalos de distinto tamaño.

Así, obtenemos métricas más robustas, interpretables y coherentes con la naturaleza del problema.

Máster Universitario en Inteligencia Computacional e Internet de las Cosas

Aprendizaje Profundo

*Adapting performance metrics for ordinal
classification to interval scale: length matters*

Autor:

Marcos Rivera Gavilán

Profesores:

Pedro Antonio Gutierrez Peña

Javier Sánchez Monedero